Performance Analysis for Projection-Correction Methods in Motion Deblurring Problems

Sara Casadio, Enrico Ferraiolo, Giovanni Maria Savoca

Alma Mater Studiorum - Università di Bologna
Corso di Laurea in Informatica

2 giugno 2025

Problem Description

- The project analyzes the performance of two **Projection-Correction** algorithms for reconstructing medical images affected by **motion blur**.
- The studied algorithms are:
  - **Diffusion Posterior Sampling (DPS)**
  - **Regularization by Denoising with Diffusion (RED-Diff)**
- Both methods are based on **pre-trained diffusion models**.
- Objective: evaluate the effectiveness of these methods in recovering degraded images.

Approach to the Problem

- **Objective**: Analyze the performance of *Projection-Correction* methods **DPS** and **RED-Diff** for motion blur removal on medical images
- **Phase 1**: Dataset preprocessing (128x128)
- **Phase 2**: Data augmentation to increase dataset diversity
- **Phase 3**: Training a DDIM diffusion model on medical data
- **Phase 4**: Simulation of motion blur and its removal
- **Phase 5**: Implementation and comparison of *Projection-Correction* methods: **DPS** and **RED-Diff**
- **Phase 6**: Quantitative evaluation of performance using metrics such as **PSNR** and **SSIM**

Dataset Origin

- We use the "Mayo Clinic CT Dataset" of low-dose CT scans, available via the link provided in this report.
- It contains a total of 6,400 2D slices in PNG format, extracted from 20 different patients.
- The images are organized into:
  - `raw_data/train/`: 5,120 slices for training (80% of the dataset)
  - `raw_data/test/`: 1,280 slices for testing (20% of the dataset)

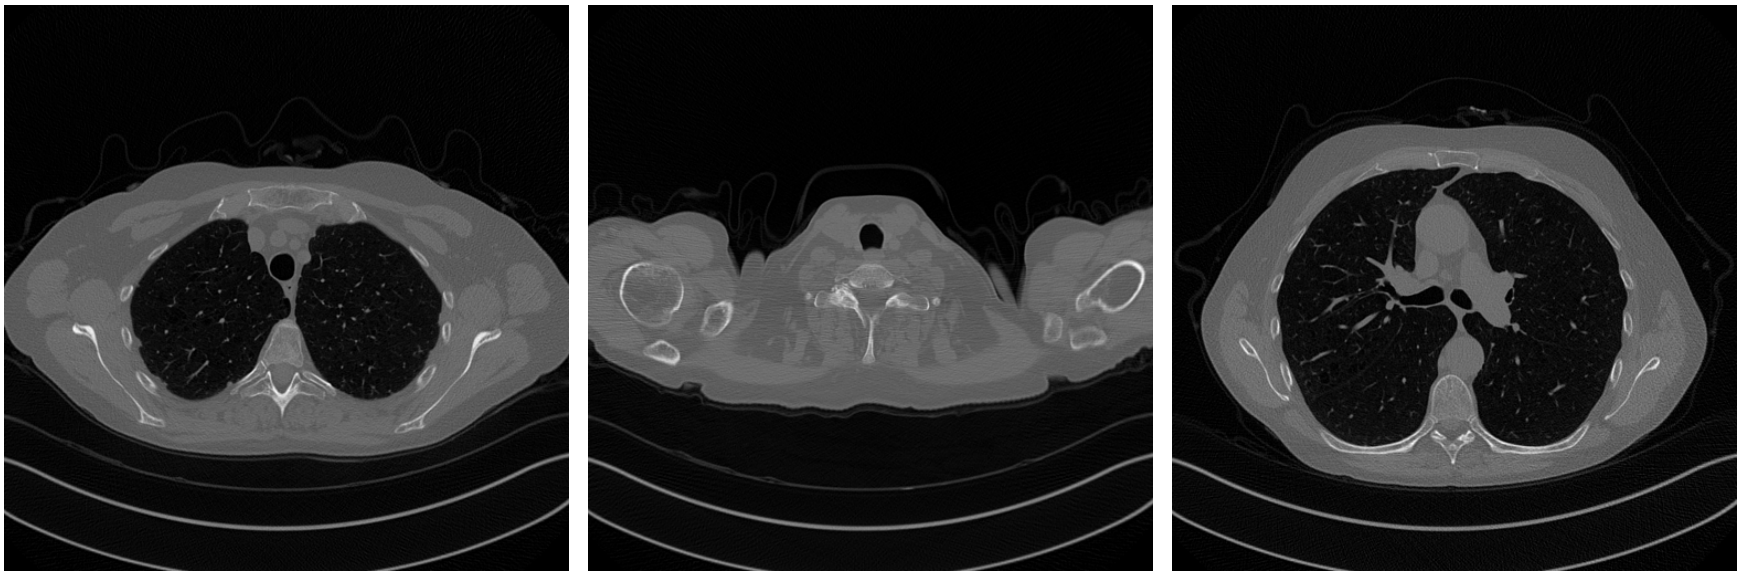

Figura: Examples of CT slices from the Mayo Clinic dataset

Conversion Pipeline

Before applying augmentations, each image is converted using:

1. **Grayscale**: single channel via `transforms.Grayscale(num_output_channels=1)`
2. **Resize**: to 128×128 pixels using bicubic interpolation
3. **Normalization**: values scaled to $[-1, 1]$ using mean 0.5 and std 0.5

```
base_transform = transforms.Compose([
    transforms.Grayscale(1),
    transforms.Resize((128,128), interpolation=Image.BICUBIC),
    transforms.ToTensor(),
    transforms.Normalize([0.5], [0.5]),
])
```

Data Augmentation: Types

For each clean image, we apply the following transformations:

- **Fixed rotations**: $\pm 5^\circ$ via `rotate_fixed()`
- **Horizontal flip**: `horizontal_flip()`
- **Gaussian noise**: mean 0, std 10 via `add_gaussian_noise()`
- **Salt-and-pepper noise**: probability 2% via `add_salt_pepper()`
- **Brightness adjustment**: factor 1.2 via `change_brightness()`
- **Contrast adjustment**: factor 1.3 via `change_contrast()`

Repository Organization

- `raw_data/`: directory containing CT slice images (`train/`, `test/`)
- `checkpoints/`: saved model weights (`*.pth`)
- `scripts/`: main scripts for training and evaluation
- `utils.py`: module with utility functions (dataset, model, checkpoint I/O)
- `notebooks/`: exploratory and prototyping notebooks
- `result/`: output images, plots, and metrics
- `report/`: report materials (`media/`, `capitoli/`)

Training Pipeline

- **Obiettivo**: Train a denoising diffusion model (DDIM U-Net) su immagini in scala di grigi
- **Componenti principali**:
  1. Data Augmentation
  2. DataLoader
  3. Compilazione del modello
  4. Loop di training con mixed-precision

Data Augmentation

- **Base Dataset**: Dataset Mayo
  - Grayscale $\rightarrow$ 1 channel
  - Resize images to 128×128
- **Augmentations** (8 types):
  - *None*: no transformation
  - `Rotation` $\pm 5^{\circ}$ (rotation + centering)
  - `Flip` horizontal
  - `Gaussian noise` (mean=0, std=10)
  - `Salt and pepper noise` (prob=2%)
  - `Brightness` (factor=1.2)
  - `Contrast` (factor=1.3)
- **Implementazione essenziale**:

Schedulers for Diffusion

- **DDPMScheduler** for training diffusion process
  - `Timesteps` 1000
- **DDIMScheduler** for sampling
  - `Timesteps` 1000

Compiling the Model

- **Why**: optimize the model for better performance
- **Usage**:

```
model = torch.compile(model)
```

- **Benefits**: improved batch throughput

Mixed-Precision with AMP

- **GradScaler amd autocast**:
  - `GradScaler` for scaling gradients
  - `autocast` for automatic mixed precision
- Reduce memory usage and speed up training

Training Loop

1. Loss function: `MSE`
2. Start the training `model.train()`
3. For each epoch:
   - Move images to GPU (if available)
   - Generate noise and timesteps
   - Compute noise prediction on the input data
   - Prediction + MSE loss
   - Optimization + `scheduler.step()`
4. Save validation samples to visualize the model performance during training
5. Compute and log average losses
6. Save model weights each epoch

Validation and Checkpointing

- **Validation**:
  - `model.eval()` to set the model to evaluation mode
  - MSE loss on validation set
- **Checkpoint**:
  - Save the model weights to a `.pth` file
  - Update loss, PSNR and SSIM history in `history.txt`
- Monitor train vs validation loss over epochs aswell as PSNR and SSIM between the generated and original images
  - For each epoch sample 10 images from the validation set and compute the metrics

Loss Plot

- **Loss Plot**: visualizes the training and validation loss over epochs
- **Purpose**:
  - Monitor the model's performance

Sottosezione 2.1

Che cosa fa DPS

Diffusion Posterior Sampling (DPS) è un metodo per risolvere problemi inversi rumorosi sfruttando modelli di diffusione come prior implicito.

- A partire da un'immagine distorta $y = K(x_0) + n$, integra direttamente il termine di verosimiglianza nel processo di campionamento della diffusione inversa.
- Al passo t, DPS calcola una predizione $\hat{x}_0$ e utilizza il gradiente di $\|y - K(\hat{x}_0)\|^2$ per muoversi verso soluzioni compatibili con i dati osservati.
- Rispetto ai metodi basati su proiezioni dure, DPS mantiene la traiettoria sulla varietà generativa, riducendo l'amplificazione del rumore.

Implementazione di DPS

L'algoritmo si sviluppa in tre fasi principali:

1. **Predizione iniziale:** si genera $x_T \sim \mathcal{N}(0, I)$, quindi per ogni passo t il modello UNet stima il rumore $s_\theta(x_t, t)$ e ricostruisce $\hat{x}_0$.
2. **Aggiornamento posteriore:** si calcola il gradiente di verosimiglianza $\nabla = -K^T(y - K(\hat{x}_0))$ e si applica un passo proporzionale a $\gamma_t = \frac{1-\bar{\alpha}_t}{\sigma_y^2+(1-\bar{\alpha}_t)}$ per ottenere $\tilde{x}_{t-1}$.
3. **Passo DDIM modificato:** usando $\tilde{x}_{t-1}$ come riferimento, si esegue il classico update DDIM per passare a x_{t-1}, preservando l'effetto del gradiente di verosimiglianza.

L'implementazione richiede pochi passaggi in PyTorch, integrando le funzioni di blur e i relativi operatori adjoint.

Risultati finali

- Su dataset con blur da movimento, DPS raggiunge PSNR medio superiore a 25 dB e SSIM superiore a 0.85, migliorando di oltre 2 dB rispetto a metodi basati su proiezioni dure.
- Il confronto con metodi classici mostra una riduzione significativa dell'artifatto di ricostruzione, mantenendo dettagli fini e bordi netti.
- Visualmente, le immagini ricostruite con DPS appaiono più naturali e prive di artefatti di overshooting, grazie al controllo continuo del contributo della verosimiglianza.

Che cosa fa RED-Diff

RED-Diff risolve problemi inversi rumorosi combinando:

- Un termine di fidelity per avvicinare la ricostruzione alle osservazioni y,
- Un regolarizzatore basato sui denoiser multiscala di un modello di diffusione pre-addestrato,

integrando vincoli a diversi livelli di dettaglio per preservare sia le strutture globali che i dettagli fini.

Implementazione di RED-Diff

L'algoritmo si articola in tre fasi principali:

1. **Inizializzazione:** $\mu^{(0)} = K^T y$.
2. **Ottimizzazione iterativa:** Per ogni passo $i = 1, \ldots, N$ e per ogni livello di rumore $t = 1, \ldots, T$:
   1. Campiona $\epsilon \sim \mathcal{N}(0, I)$ e costruisci
   $$x_t = \sqrt{\alpha_t}\, \mu^{(i-1)} + \sigma_t\, \epsilon.$$
   2. Predici il rumore $\hat{\epsilon} = \epsilon_\theta(x_t, t)$.
   3. Calcola i contributi:
   $$L_{\text{fid}} = \tfrac{1}{2\sigma_y^2} \|K\mu^{(i-1)} - y\|^2, \quad L_{\text{reg}} = w_t\, \|\hat{\epsilon} - \epsilon\|^2, \quad w_t = 1/\text{SNR}_t.$$

   Quindi aggiorna $\mu^{(i)}$ con Adam minimizzando $L_{\text{fid}} + \lambda\, L_{\text{reg}}$.
3. **Output:** la stima finale $\mu^{(N)}$.

Risultati finali

- Su test di deblurring, RED-Diff raggiunge PSNR medio di $\approx 19.4\,\text{dB}$, SSIM di ≈ 0.64.
- Confrontato a metodi senza prior diffusivo, migliora la qualità ricostruttiva di $> 2\,\text{dB}$ di PSNR.
- Le ricostruzioni mostrano dettagli più nitidi e minor artefatti, grazie all'integrazione multiscala del denoising.

Sottosezione 2.1

Sottosezione 2.1

Conclusioni

Grazie per l'attenzione